Instituto Profesional Duoc UC.
Escuela de Informática y Telecomunicaciones
Sede: Plaza Norte

“SaludConex: Sistema de Predicción de Inasistencias Médicas”

Bastian Ignacio Roman Fuenzalida

Ignacio Andres Gomez Olate

Vicente Contreras

Sección: 001-D

Nombre del docente: Osnellys E, Andrade D.

1. Introducción y estado general del proyecto

Este informe documenta la ejecución del proyecto SaludConex, cuyo objetivo es estimar el riesgo de inasistencia de cada reserva médica para focalizar acciones preventivas (recordatorios adicionales, confirmación anticipada o contacto telefónico), sin cancelar ni negar atenciones de forma automática. El trabajo sigue el plan definido en EP3 bajo la metodología CRISP-DM y compara lo planificado con lo efectivamente ejecutado.

Estado al cierre de EP5: se completaron la exploración, la preparación de datos, el modelamiento y la evaluación en Python, y se construyó un entregable funcional compuesto por un modelo de Regresión Logística, dos archivos de resultados y un dashboard de tres páginas en Looker Studio. El avance ponderado por entregables es de **79 %** (sección 3.3). Quedan pendientes el análisis por comuna y previsión, el piloto con usuarios y la capacitación.

Advertencia: no se dispuso de datos históricos reales de SaludConex. Se trabajó con un conjunto **sintético de 50.000 reservas**, por lo que las métricas describen una simulación académica y no el comportamiento real de pacientes o centros.

Tabla 1. *Evidencias del proyecto y enlaces de acceso*

Evidencia	Contenido	Enlace
Notebook (Google Colab)	SaludConex.ipynb: exploración, preparación, modelamiento, evaluación y exportación	**SaludConex**
Repositorio	Notebook, dataset sintético y archivos CSV generados	**https://github.com/BRomanman/SaludConex-Sistema-Prediccion-Inasistencias.git**
Dashboard Looker Studio	Resumen general, análisis de riesgo y evaluación del modelo	**https://datastudio.google.com/reporting/ede2ed46-e9da-4252-95a9-da02b138c71c**
Tablero Trello	SCY1102 – SaludConex | EP5 Ejecución y EP6 Presentación	**https://trello.com/invite/b/6aee0c16a1b5c786487b1c78/ATTI58f23117ed4c43d4a84ef31ec54a58b5AA3BE3C3/scy1102-saludconex-ep5-ejecucion-y-ep6-presentacion**

2. Implementación técnica del proyecto

2.1. Herramientas y flujo de trabajo

El desarrollo se realizó en **Python sobre Google Colab** con pandas y NumPy (manipulación), Matplotlib y Seaborn (visualización) y scikit-learn (preprocesamiento, modelos y métricas). Los resultados se exportaron a CSV y se visualizaron en **Looker Studio**; la gestión se llevó en **Trello**. El notebook sigue las fases de CRISP-DM y documenta cada celda con su objetivo e interpretación, lo que asegura trazabilidad entre datos, modelo, predicciones y dashboard.

2.2. Comprensión y preparación de los datos

El dataset tiene **50.000 registros y 18 variables**. El control de calidad no encontró valores nulos, reservas duplicadas, edades fuera de rango ni fechas inconsistentes. La tasa de inasistencia fue cercana al 18 % y varió poco entre especialidades (15,1 % en Pediatría a 17,7 % en Traumatología) y centros (16,3 % en La Florida a 18,6 % en Ñuñoa). El patrón más marcado fue la anticipación: las reservas tomadas con 61–90 días alcanzaron 34,4 %, aunque ese grupo solo tiene 61 registros (Figura 1).

En la preparación se **excluyeron 2.988 reservas canceladas**, porque el objetivo es anticipar la inasistencia sin aviso y no la cancelación, quedando 47.012 registros. Se definió la variable objetivo binaria (1 = inasistencia) y se seleccionaron **14 predictoras** (5 numéricas y 9 categóricas), excluyendo identificadores, profesional y fechas directas. Un pipeline con *ColumnTransformer* imputa (mediana / moda), estandariza y aplica One-Hot, generando 64 columnas.

Para **evitar fuga de información** se excluyó el resultado de la reserva y todo dato derivado de él, y el preprocesador se ajustó solo con entrenamiento. *Confirmacion_Recordatorio* se usa bajo el supuesto de que la predicción se ejecuta después del recordatorio de 24 horas. La partición fue **temporal** (corte 06-04-2026): 37.569 reservas de entrenamiento y 9.443 de prueba, con proporciones de inasistencia similares (17,9 % y 18,1 %). Dentro del entrenamiento se separó un periodo de validación (corte 22-10-2025) para elegir modelo y umbral.

2.3. Modelamiento y evaluación

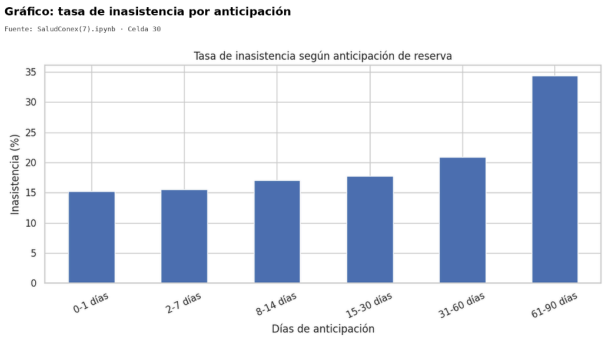
Se compararon un **Baseline** (clase más frecuente), **Regresión Logística** y **Random Forest** (150 árboles), ambos con *class_weight="balanced"* por el desbalance de clases. El Baseline obtiene 82 % de exactitud sin detectar ninguna inasistencia, lo que muestra que Accuracy no sirve como criterio. Random Forest tuvo mayor precisión pero solo detectó el 6,7 % de las inasistencias; por eso se eligió la **Regresión Logística**, alineada con la métrica prioritaria definida en EP3 (Recall) y más fácil de explicar al personal administrativo.

Luego se ajustó el umbral maximizando el F1-Score en validación: con **0,453** el Recall subió de 54,4 % a 71,1 %, a cambio de más falsas alertas. El modelo se reentrenó con todo el entrenamiento y se evaluó una sola vez sobre las 9.443 reservas de prueba (Tabla 2 y Figura 1).

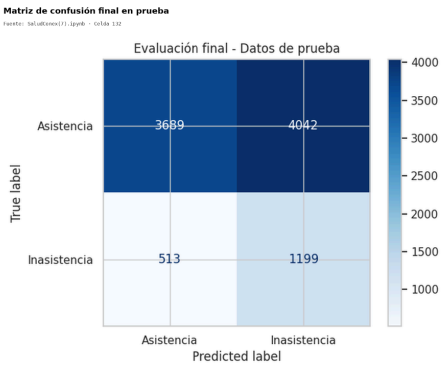
Tabla 2. *Comparación de modelos en validación y resultado final en prueba*

Modelo	Conjunto	Accuracy	Precision	Recall	F1	AUC-ROC
Baseline	Validación	0,821	0,000	0,000	0,000	0,500
Random Forest (0,50)	Validación	0,809	0,341	0,067	0,112	0,596
Reg. Logística (0,50)	Validación	0,594	0,231	0,544	0,325	0,611
Reg. Logística (0,453)	Validación	0,492	0,218	0,711	0,334	0,611
Reg. Logística (0,453)	**Prueba**	**0,518**	**0,229**	**0,700**	**0,345**	**0,630**

Figura 1. *Inasistencia según anticipación (izq.) y matriz de confusión en prueba (der.)*



Fuente: SaludConex.ipynb, celda 30



Fuente: SaludConex.ipynb, celda 132

En prueba el modelo detecta **7 de cada 10 inasistencias** (1.199 de 1.712), pero su precisión es de 22,9 %: de cada 10 alertas, unas 2 corresponden a inasistencias reales. El AUC-ROC de 0,630 indica una discriminación superior al azar, aunque moderada. Por segmentos, el Recall se mantuvo

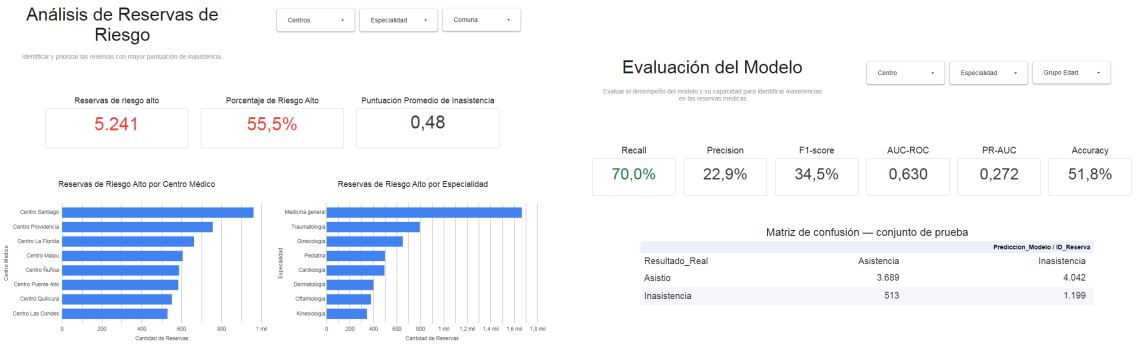
entre 0,65 y 0,73 por grupo de edad y entre 0,63 (Puente Alto) y 0,78 (Ñuñoa) por centro; estas diferencias no prueban un sesgo, pero se deben seguir monitoreando.

2.4. Entregable funcional: archivos de resultados y dashboard

Se generaron dos archivos con las 9.443 reservas de prueba, separados según su uso: **SaludConex_Predicciones_Looker.csv** (13 columnas, sin el resultado real) con puntaje, umbral, nivel de riesgo y alerta preventiva, y **SaludConex_Evaluacion_Modelo.csv** (8 columnas) que compara la predicción con lo ocurrido. La separación evita usar el resultado real, conocido solo después de la cita, como dato operativo.

El dashboard en Looker Studio tiene tres páginas con filtros por centro, especialidad, comuna y edad: **Resumen General** (volumen y distribución del riesgo), **Análisis de Reservas de Riesgo** (5.241 reservas en riesgo alto y tabla priorizada por puntaje) y **Evaluación del Modelo** (métricas, matriz de confusión y Recall por centro y edad). Los indicadores se contrastaron con los resultados de Python y coinciden (Recall 70,0 %, Precision 22,9 %, AUC-ROC 0,630).

Figura 2. *Páginas Análisis de Reservas de Riesgo (izq.) y Evaluación del Modelo (der.) en Looker Studio*



3. Monitoreo y control del proyecto

3.1. Herramienta de gestión

El proyecto se controló en el tablero de Trello **"SCY1102 – SaludConex | EP5 Ejecución y EP6 Presentación"**, organizado en seis listas: Planificación y pendientes, En desarrollo, En revisión y validación, Completado, Desviaciones y acciones correctivas, y Bloqueado. Cada tarjeta incluye responsable (prefijos **BAS**, **IGN** y **VIC**), descripción, prioridad, evidencia requerida y fechas planificadas y reales (Figura 3).

Figura 3. *Tablero de seguimiento del proyecto en Trello*

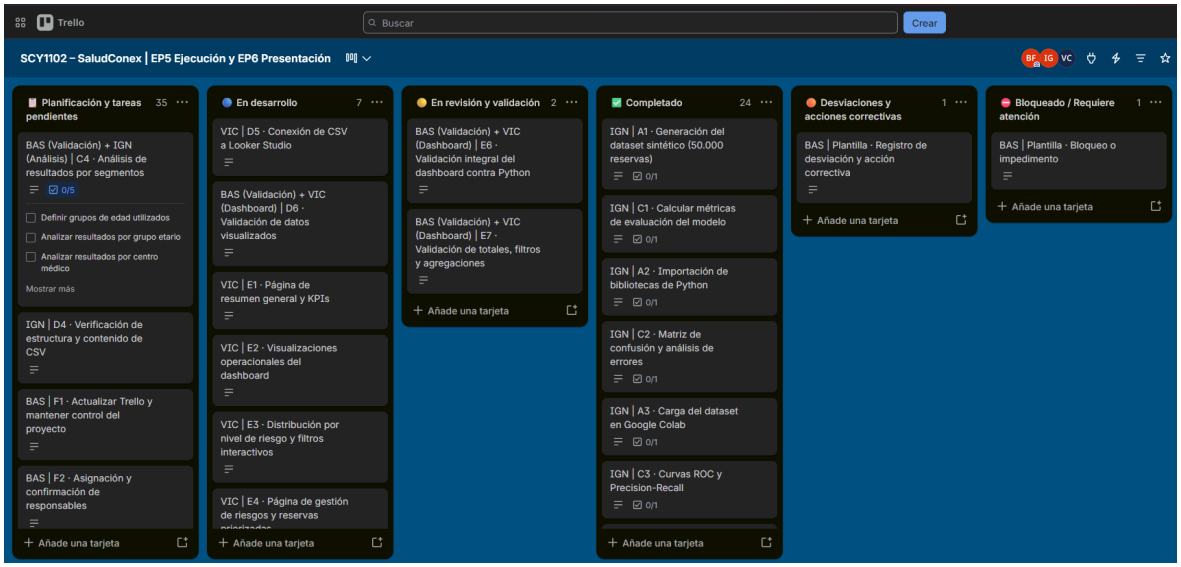


Tabla 3. *Distribución de responsabilidades*

Integrante	Código	Responsabilidades ejecutadas
Bastián Román	BAS	Coordinación y seguimiento, mantención del tablero, análisis de resultados por segmentos y documentación del informe.
Ignacio Gómez	IGN	Preparación de datos, selección de variables, tratamiento de cancelaciones, prevención de fuga de información, partición temporal, entrenamiento y ajuste del umbral.
Vicente Contreras	VIC	Desarrollo y configuración del dashboard en Data Studio, conexión de los archivos CSV como fuentes de datos, construcción de las páginas Resumen General, Análisis de Reservas de Riesgo y Evaluación del Modelo, implementación de visualizaciones, filtros interactivos y tablas de reservas priorizadas, además de la preparación de capturas de evidencia.

3.2. Tareas planificadas versus ejecutadas

La Tabla 4 compara cada fase del plan de EP3 con lo ejecutado. Los códigos D1–D6 remiten a las desviaciones de la sección 3.4.

Tabla 4. *Planificación EP3 versus ejecución por fase de CRISP-DM*

Fase (plan EP3)	Planificado	Ejecutado	Estado
1. Negocio (S1–2)	Requerimientos, MoSCoW, Recall como métrica prioritaria.	Documentado en EP3; Recall usado para elegir modelo y umbral.	Completado
2. Datos (S2–4)	EDA de 3 años de datos reales; faltantes por centros migrados.	EDA y control de calidad de 50.000 reservas sintéticas.	Completado con desviación (D1)
3. Preparación (S4–8)	Extracción SQL, tratamiento de faltantes, variables derivadas, partición temporal.	Exclusión de canceladas, 14 predictoras, pipeline y partición temporal.	Completado (D1)

Fase (plan EP3)	Planificado	Ejecutado	Estado
4. Modelamiento (S8–12)	Reg. Logística, Random Forest y Gradient Boosting; validación cruzada temporal; scoring.	Baseline, Reg. Logística y Random Forest; validación temporal simple; puntajes en CSV.	Completado con desviación (D3)
5. Evaluación (S12–13)	Métricas, análisis por centro, edad, comuna y previsión; comparación con regla simple.	Métricas, ajuste de umbral y análisis por centro y edad.	Parcial (D4, D5)
6. Despliegue (S12–18)	Dashboard en Power BI, piloto, capacitación y documentación.	Dashboard en Data Studio e informe técnico.	Parcial (D2, D6)

3.3. Reporte de estado de avance

El avance se calculó sobre los siete entregables de EP3, asignando 1 a los completados, 0,5 a los parciales y 0 a los no iniciados: (4 × 1 + 3 × 0,5) / 7 = **78,6 %**. Según las tarjetas de Trello, se encuentran completadas 50 de las 85 tarjetas registradas, equivalente a un avance general por tareas del **58,8 %**.

Tabla 5. *Estado de los entregables planificados*

Entregable	Hito	Estado	Evidencia o pendiente
E1 Requerimientos y alcance	H1 (S2)	Completado	Informe EP3
E2 Diagnóstico de calidad de datos	H2 (S4)	Completado	Notebook, sección de exploración
E3 Dataset analítico y pipeline	H3 (S8)	Completado	Notebook, pipeline de preprocesamiento
E4 Modelo y scoring	H4 (S10)	Completado	Modelo final y CSV de predicciones
E5 Informe de evaluación	H5 (S13)	Parcial	Falta análisis por comuna y previsión y comparación con regla simple
E6 Dashboard validado en piloto	H6 (S16)	Parcial	Dashboard funcional; piloto no ejecutado
E7 Documentación y capacitación	H7 (S18)	Parcial	Informe y evidencias; capacitación pendiente

3.4. Desviaciones y acciones correctivas

Tabla 6. *Desviaciones respecto del plan, causas, impacto y acciones (riesgo EP3 asociado)*

ID	Desviación	Causa	Impacto	Acción correctiva
D1 (R1, R3)	Dataset sintético de 50.000 reservas en lugar de 3 años de datos reales.	No se dispuso de datos autorizados de SaludConex.	Métricas no extrapolables; no se evaluaron registros migrados.	Advertencia en notebook, dashboard e informe; pipeline reproducible para reejecutar con datos reales.

ID	Desviación	Causa	Impacto	Acción correctiva
D2 (R6)	Data Studio en lugar de Power BI.	Mayor familiaridad del equipo con Looker Studio, herramienta trabajada previamente en clases, lo que facilitó su implementación.	Rediseño de la integración entre Python y la visualización.	Exportación a dos CSV y verificación de que los indicadores del dashboard coinciden con Python.
D3	Sin Gradient Boosting ni validación cruzada temporal.	Se priorizó un modelo interpretable y el entregable funcional dentro del plazo.	Menor exploración de modelos.	Validación temporal simple y comparación con Baseline y Random Forest; queda como mejora.
D4	Recall bajo con umbral 0,50 por desbalance (≈18 % de inasistencias).	Desbalance de clases.	Solo 54,4 % de inasistencias detectadas en validación.	class_weight="balanced" y umbral 0,453: Recall de 70,0 % en prueba.
D5 (R2)	Análisis por comuna y previsión y comparación con regla simple no realizados.	Se priorizaron centro y edad.	No se puede confirmar el criterio de éxito ni descartar efecto de variables proxy.	Tarea registrada como pendiente de alta prioridad en Trello.
D6 (R8)	Sin piloto, capacitación ni registro de acciones preventivas (RF04).	Requieren usuarios reales de SaludConex.	E6 y E7 quedan parciales.	Se reprograman para una fase con datos y usuarios autorizados.

4. Limitaciones y consideraciones éticas

- **Datos sintéticos:** los resultados no son indicadores reales de SaludConex y deben repetirse con datos autorizados.
- **Precisión limitada y carga operativa:** con el umbral elegido el 55,5 % de las reservas queda en riesgo alto; el umbral debe ajustarse según la capacidad real de contacto del personal.
- **Puntaje no calibrado:** *Puntaje_Inasistencia* sirve para ordenar reservas, no como probabilidad exacta.
- **Variables proxy:** el modelo usa *Comuna* y *Tipo_Previsión*, identificadas en EP1 y EP3 como posibles proxies socioeconómicos; por eso el análisis D5 es prioritario.
- **Decisión humana:** la alerta solo prioriza revisiones; el sistema no cancela, bloquea ni niega atenciones.

5. Conclusiones y próximos pasos

El proyecto ejecutó las fases de CRISP-DM hasta un entregable funcional verificable: un pipeline en Python con partición temporal y control de fuga de información, un modelo que detecta el 70 % de las inasistencias del conjunto de prueba y un dashboard que traduce el puntaje en una lista priorizada para el personal. El avance estimado es de 79 %, y las diferencias con el plan se explican principalmente por la ausencia de datos reales y de usuarios para el piloto.

Los próximos pasos son: (1) evaluar el desempeño por comuna y previsión y compararlo con una regla simple de inasistencias previas; (2) probar Gradient Boosting con validación cruzada temporal; (3) calibrar el puntaje y ajustar el umbral según la capacidad de contacto; y (4) repetir el proceso con datos autorizados y ejecutar el piloto.